ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ ΤΡΑΠΕΖΙΚΟΥ MARKETING ΜΕ ΤΗ ΧΡΗΣΗ ΤΗΣ ΓΛΩΣΣΑΣ ΠΡΟΓΡΑΜΜΑΤΙΣΜΟΥ PYTHON

Συκερίδη Δήμητρα (ΜΕ25036)
Πανεπιστήμιο Πειραιώς
Κατεύθυνση:Μεγάλα Δεδομένα και Αναλυτική
Τμήμα Ψηφιακών Συστημάτων

Κασιούμη Μαριλένα Δήμητρα (ΜΕ25016)
Πανεπιστήμιο Πειραιώς
Κατεύθυνση:Μεγάλα Δεδομένα και Αναλυτική
Τμήμα Ψηφιακών Συστημάτων

Στην παρούσα εργασία αναλύονται δεδομένα τραπεζικών καμπανιών μάρκετινγκ , με στόχο την πρόβλεψη αποδοχής προσφοράς από πελάτες. Η ανάλυση γίνεται με τη χρήση βιβλιοθηκών της γλώσσας προγραμματισμού Python. Τα δεδομένα ελήφθησαν από το UCI Machine Learning Repository. Εμφανίζονται τεχνικές μηχανικής μάθησης όπως Logistic Regression, Random Forest, KNN, SVM και XGBoost. Δίνεται έμφαση στο πρόβλημα ανισορροπίας κλάσεων και χρησιμοποιούνται τεχνικές, όπως το class weighting. Τα αποτελέσματα συγκρίνονται ώστε να εντοπιστεί το αποδοτικότερο μοντέλο.

I. ΕΙΣΑΓΩΓΗ

Η πρόβλεψη συμπεριφοράς πελατών αποτελεί σημαντικό εργαλείο στον τραπεζικό τομέα. Οι καμπάνιες μάρκετινγκ στοχεύουν στην προσέλκυση πελατών για προϊόντα όπως οι προθεσμιακές καταθέσεις. Ωστόσο, τα δεδομένα αυτά χαρακτηρίζονται από έντονη ανισορροπία κλάσεων. Στόχος της εργασίας είναι η ανάπτυξη μοντέλων ταξινόμησης και η ευρύτερη σύγκριση τους. Μέσω της αξιοποίησης τεχνικών μηχανικής μάθησης , επιτρέπεται η εξαγωγή χρήσιμων προτύπων από τα δεδομένα και η λήψη τεκμηριωμένων επιχειρησιακών αποφάσεων.

II. ΜΕΘΟΔΟΛΟΓΙΑ

Το πρώτο στάδιο της ανάλυσης περιλάμβανε τη φόρτωση και αρχική εξερεύνηση του συνόλου δεδομένων. Εξετάστηκαν το πλήθος εγγραφών, οι τύποι μεταβλητών και ύπαρξη πιθανών ασυνεπειών. Το σύνολο δεδομένων περιλαμβάνει δημογραφικά και οικονομικά χαρακτηριστικά πελατών. Ιδιαίτερη προσοχή δόθηκε στη μεταβλητή-στόχο που δείχνει εάν ο πελάτης αποδέχτηκε την προσφορά. Για την μεταβλητή-στόχο παρατηρήθηκε έντονη ανισορροπία μεταξύ των δύο κλάσεων. Η διερεύνηση αυτή ανέδειξε ότι απλή χρήση της ακρίβειας ως μέτρο αξιολόγησης δεν είναι επαρκής. Ένα μοντέλο που προβλέπει πάντα την πλειοψηφική κλάση μπορεί να εμφανίζει υψηλή ακρίβεια, χωρίς όμως πρακτική χρησιμότητα. Συνεπώς, κρίθηκε απαραίτητη η χρήση μετρικών όπως precision, recall και F1-score, ιδίως για την μειοψηφική κλάση (το οποίο προτείνεται από την βιβλιογραφία [1]). Στην συγκεκριμένη υλοποίηση χρησιμοποιήθηκε ανεξάρτητο test set για αξιολόγηση σε εντελώς άγνωστα δεδομένα με επέκταση της τεχνικής cross-validation με στόχο μία όσο το δυνατόν αμερόληπτη εκτίμηση της απόδοσης του μοντέλου. Τα δεδομένα χωρίζονται σε ίσα τμήματα παρένθεση (folds) για παράδειγμα όταν ορίζεται 10 folds cross-validation το σύνολο δεδομένων χωρίζεται σε 10 υποσύνολα και σε κάθε επανάληψη τα 9 χρησιμοποιούνται για εκπαίδευση και το ένα για επικύρωση. Η διαδικασία επαναλαμβάνεται 10 φορές ώστε κάθε υποσύνολο να χρησιμοποιηθεί μία φορά ως σύνολο επικύρωσης. Η τελική επίδοση προκύπτει ως ο μέσος όρος των επιμέρους αποτελεσμάτων.

A. Εισαγωγή δεδομένων στη γλώσσα προγραμματισμού Python

Τα δεδομένα που χρησιμοποιήθηκαν στην παρούσα μελέτη προέρχονται από το αρχείο bank marketing dataset (bank full.csv) ,το οποίο αποτελεί ένα ευρέως γνωστό σύνολο δεδομένων στη βιβλιογραφία της μηχανικής μάθησης, για προβλήματα πρόβλεψης απόκρισης πελατών σε τραπεζικές καμπάνιες μάρκετινγκ. Το αρχείο περιλαμβάνει καταγραφές πραγματικών καμπανιών άμεσου μάρκετινγκ , στις οποίες οι πελάτες προσεγγίστηκαν κυρίως μέσω τηλεφωνικής επικοινωνίας. Η εισαγωγή δεδομένων πραγματοποιήθηκε σε περιβάλλον Python με τη χρήση της βιβλιοθήκης ανάλυσης δεδομένων Pandas, μέσω ανάγνωσης αρχείου CSV με κατάλληλο διαχωριστικό χαρακτήρα.

Μετά την εισαγωγή, ακολούθησε έλεγχος της δομής του πίνακα δεδομένων, των τύπων μεταβλητών και της συνοχής των εγγράφων. Το σύνολο δεδομένων περιλαμβάνει δημογραφικά χαρακτηριστικά (όπως ηλικία, επάγγελμα και οικογενειακή κατάσταση), οικονομικά στοιχεία, καθώς και πληροφορίες σχετικά με το ιστορικό επικοινωνίας του πελάτη με την τράπεζα. Η μεταβλητή–στόχος αποτυπώνει αν ο πελάτης αποδέχθηκε ή όχι την προτεινόμενη τραπεζική προσφορά. Η κατανόηση της δομής και του περιεχομένου των δεδομένων αποτέλεσε βασικό βήμα πριν την εφαρμογή τεχνικών προεπεξεργασίας και μοντελοποίησης.

B. Βήματα προεπεξεργασίας

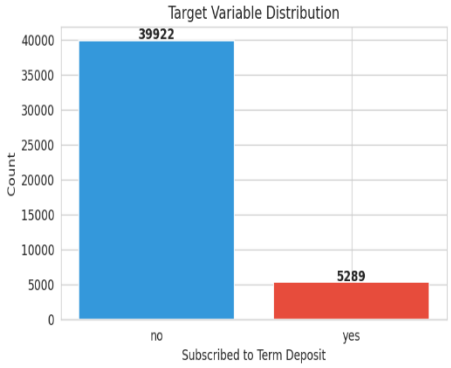

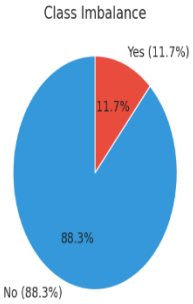

Η προεπεξεργασία των δεδομένων αποτέλεσε κρίσιμο στάδιο της παρούσας μελέτης , καθώς η ποιότητα και η μορφή των δεδομένων επηρεάζουν άμεσα την απόδοση και την γενικευσιμότητα των μοντέλων μηχανικής μάθησης. Πριν από την εκπαίδευση των μοντέλων , πραγματοποιήθηκε συστηματικός έλεγχος της δομής του συνόλου δεδομένων, της κατανομής των κλάσεων και της πληρότητας των μεταβλητών. Η μεταβλητής-στόχος παρουσιάζει σημαντική ανισορροπία. Συγκεκριμένα, από το σύνολο των παρατηρήσεων, 39.922 αντιστοιχούν στην κλάση “no” , δηλαδή το 88.3% και 5.289 στην κλάση “yes” , δηλαδή τα 11.7%.

Η κατανομή αυτή υποδηλώνει έντονη υπεροχή της αρνητικής κλάσης, γεγονός που μπορεί να επηρεάσει αρνητικά την εκπαίδευση των μοντέλων , καθώς πολλά μοντέλα τείνουν να ευνοούν την πλειοψηφική κλάση. Η διαπίστωση αυτή ενίσχυση την ανάγκη για κατάλληλες τεχνικές εξισορρόπησης και προσεκτικής επιλογής μετρικών αξιολόγησης. Παράλληλα, διαπιστώθηκε ότι το σύνολο δεδομένων δεν περιέχει κενές τιμές, γεγονός που απλοποιεί σημαντικά τη διαδικασία προεπεξεργασίας, καθώς δεν απαιτήθηκαν τεχνικές συμπλήρωσης ελλιπών δεδομένων (imputation). Ωστόσο, η απουσία κενών τιμών δεν αναιρεί την ανάγκη για προσεκτικό μετασχηματισμό και επιλογή χαρακτηριστικών. Σε πρώτο στάδιο, πραγματοποιήθηκε αφαίρεση ορισμένων χαρακτηριστικών που κρίθηκαν αμφιλεγόμενα ως προς τη διαρροή πληροφορίας όπως (π.χ το duration). Ορισμένες μεταβλητές, σε παρόμοια σύνολα δεδομένων περιέχουν πληροφορία που είναι διαθέσιμη μόνο μετά την ολοκλήρωση της επικοινωνίας με τον πελάτη.

Η διατήρησή της θα οδηγούσε σε μη ρεαλιστικά υψηλή απόδοση του μοντέλου, καθώς θα αξιοποιούσε πληροφορία που δεν θα ήταν διαθέσιμη σε πραγματικές συνθήκες πρόβλεψης. Η απομάκρυνση τέτοιων μεταβλητών διασφαλίζει ότι το μοντέλο εκπαιδεύεται σε ρεαλιστικό πλαίσιο και βασίζεται αποκλειστικά σε πληροφορία διαθέσιμη πριν από την έκβαση της καμπάνιας. Στη συνέχεια, εφαρμόστηκε feature engineering με στόχο τη βελτίωση της αναπαράστασης της πληροφορίας.

Συγκεκριμένα, η μεταβλητή που αφορά το επάγγελμα των πελατών, αρχικά περιλάμβανε μεγάλο αριθμό διακριτών κατηγοριών, γεγονός που αυξάνει τη διαστασιμότητα του προβλήματος και μπορεί να οδηγήσει σε αραιά δεδομένα. Για τον λόγο αυτό πραγματοποιήθηκε ομαδοποίηση των επαγγελμάτων σε ευρύτερες θεματικές κατηγορίες.

Τα επαγγέλματα διοικητικού και τεχνικού χαρακτήρα εντάχθηκαν σε κατηγορία “Office”, τα χειρωνακτικά επαγγέλματα στην κατηγορία “Manual” οι ελεύθεροι επαγγελματίες και επιχειρηματίες στην κατηγορία “Self-Employed”, ενώ κατηγορίες όπως άνεργοι φοιτητές και συνταξιούχοι συγκεντρώθηκαν στην κατηγορία “Not Working”. Οι περιπτώσεις άγνωστου επαγγέλματος διατηρήθηκαν σε ξεχωριστή κατηγορία “Unknown”. Στη συνέχεια η νέα ομαδοποιημένη μεταβλητή χρησιμοποιήθηκε ως είσοδος για την κωδικοποίηση των κατηγορικών δεδομένων.

Οι κατηγορικές μεταβλητές κωδικοποιήθηκαν με τη μέθοδο one-hot encoding, ώστε να μετατραπούν σε αριθμητική μορφή κατάλληλη για χρήση από τους αλγόριθμους μηχανικής μάθησης. Η τεχνική αυτή επιτρέπει την αναπαράσταση κάθε κατηγορίας ως ξεχωριστή δυαδική μεταβλητή, χωρίς να εισάγει τεχνητή διάταξη μεταξύ των κατηγοριών.

Η τεχνική one-hot encoding εφαρμόστηκε σε πολυκατηγορικές μεταβλητές όπως η οικογενειακή κατάσταση (marital), το επίπεδο εκπαίδευσης (education) και το αποτέλεσμα προηγούμενης καμπάνιας (poutcome). Για κάθε πιθανή κατηγορία , δημιουργήθηκε ξεχωριστή δυαδική στήλη, επιτρέποντας στα μοντέλα να αναγνωρίζουν ανεξάρτητα τη συμβολή κάθε κατηγορίας στην πρόβλεψη. Συνολικά , η διαδικασία κωδικοποίησης διασφάλισε ότι όλα τα κατηγορικά δεδομένα μετατράπηκαν σε κατάλληλη αριθμητική μορφή, καθιστώντας τα συμβατά με τις απαιτήσεις των αλγόριθμων μηχανικής μάθησης και υποστηρίζοντας την αξιόπιστη εκπαίδευση των μοντέλων.

Παράλληλα, οι δυαδικές μεταβλητές μετατράπηκαν σε αριθμητικές τιμές 0 και 1 ώστε να μπορούν να αξιοποιηθούν άμεσα από τα μοντέλα μηχανικής μάθησης Συγκεκριμένα, μεταβλητές όπως το ιστορικό πιστωτικής αθέτησης (default), η ύπαρξη στεγαστικού δανείου (housing) και ύπαρξη προσωπικού δανείου (loan) κωδικοποιήθηκαν σε δυαδική αριθμητική μορφή. Η μετατροπή αυτή παρέχει μία απλή και σαφή αναπαράσταση μεταβλητών τύπου ναι/όχι χωρίς απώλεια πληροφορίας και χωρίς να αλλοιώνεται η σημασιολογική τους ερμηνεία. Η δυαδική κωδικοποίηση θεωρείται κατάλληλη για τέτοιου τύπου μεταβλητές , καθώς επιτρέπει στα μοντέλα να αξιοποιούν άμεσα την πληροφορία χωρίς να απαιτούνται επιπλέον μετασχηματισμοί.

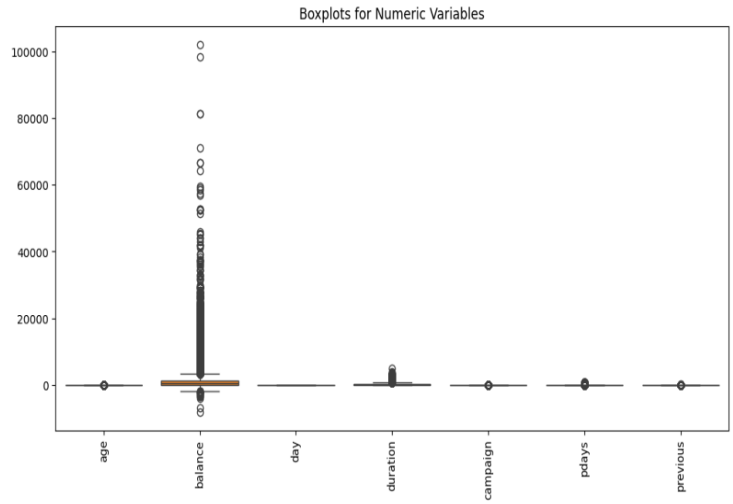

Όσον αφορά τις ακραίες τιμές (outliers) πραγματοποιήθηκε διερεύνηση των αριθμητικών μεταβλητών με στόχο τον εντοπισμό πιθανών ακραίων παρατηρήσεων. Διαπιστώθηκε ότι ορισμένες μεταβλητές, και κυρίως η μεταβλητή που αφορά το υπόλοιπο λογαριασμού (balance), παρουσιάζουν τιμές σημαντικά υψηλότερες ή χαμηλότερες από τον μέσο όρο. Ωστόσο, οι τιμές αυτές δεν θεωρήθηκαν αποτέλεσμα σφαλμάτων καταγραφής ή ασυνέπειας στα δεδομένα, αλλά πιθανόν αντανακλούν πραγματικές διαφοροποιήσεις στην οικονομική κατάσταση των πελατών. Για τον λόγο αυτό αποφασίστηκε να μην αφαιρεθούν οι ακραίες τιμές από το σύνολο δεδομένων. Η διατήρησή τους επιτρέπει στο μοντέλο να εκπαιδευτεί σε ρεαλιστικό φάσμα τιμών και να αποτυπώσει καλύτερα την πραγματική κατανομή των οικονομικών χαρακτηριστικών .

Τέλος, πραγματοποιήθηκε διαχωρισμός των δεδομένων σε σύνολα εκπαίδευσης και ελέγχου με τρόπο που διατηρήθηκε η αναλογία των κλάσεων της μεταβλητής-στόχου στα δύο σύνολα. Η προσέγγιση αυτή είναι ιδιαίτερα σημαντική σε περιπτώσεις ανισορροπίας κλάσεων, καθώς εξασφαλίζει ότι τόσο το σύνολο εκπαίδευσης όσο και το σύνολο ελέγχου περιλαμβάνουν αντιπροσωπευτικό ποσοστό θετικών και αρνητικών παρατηρήσεων. Με τον τρόπο αυτό αποφεύγετε το ενδεχόμενο κάποιο από τα σύνολα να περιέχει δυσανάλογα πολλές ή λίγες παρατηρήσεις μειοψηφικής κλάσης, κάτι που θα μπορούσε να επηρεάσει την εκπαίδευση ή την αξιολόγηση των μοντέλων. Ο συγκεκριμένος διαχωρισμός επιτρέπει την εκπαίδευση των μοντέλων σε ένα υποσύνολο των δεδομένων και την αξιολόγηση τους σε διαφορετικό, μη χρησιμοποιημένο κατά την εκπαίδευση σύνολο. Έτσι παρέχεται μία πιο ρεαλιστική εκτίμηση της ικανότητας γενίκευσης του μοντέλου σε νέα δεδομένα και μειώνεται ο κίνδυνος υπερπροσαρμογής .

Για το μοντέλα Logistic Regression και Support Vector Machine εφαρμόστηκε τυποποίηση (standardization) στα αριθμητικά χαρακτηριστικά. Η διαδικασία αυτή μετασχηματίζει τα δεδομένα ώστε να έχουν μηδενικό μέσο όρο και μοναδιαία διασπορά. Η τυποποίηση είναι ιδιαίτερα σημαντική για τα συγκεκριμένα μοντέλα, καθώς βασίζονται σε γραμμικούς συνδυασμούς χαρακτηριστικών και επηρεάζονται από την κλίμακα των μεταβλητών. Με τον τρόπο αυτό διασφαλίζεται ότι καμία μεταβλητή δεν κυριαρχεί λόγω μεγαλύτερης αριθμητικής κλίμακας .

ΜΕΘΟΔΟΙ ΤΑΞΙΝΟΜΗΣΗΣ

Η επιλογή μοντέλων έγινε, ώστε να καλύπτει διαφορετικές μεθόδους μηχανικής μάθησης.

- Η Logistic Regression χρησιμοποιήθηκε ως γραμμικό μοντέλο αναφοράς. Προσφέρει ερμηνευσιμότητα και συχνά αποτελεί ισχυρό μοντέλο αναφοράς.
- Ο K-Nearest Neighbors επιλέχθηκε ως μέθοδος που βασίζεται σε αποστάσεις.
- Ο Support Vector Machine αξιοποιήθηκε για την ικανότητά του να διαχωρίζει κλάσεις σε υψηλές διαστάσεις.
- Ο Random Forest αντιπροσωπεύει ensemble δέντρων αποφάσεων.
- Ο XGBoost ενσωματώνει τεχνικές ενίσχυσης που διορθώνουν διαδοχικά τα σφάλματα.

Η χρήση μοντέλων διαφορετικής φύσης επιτρέπει ουσιαστική συγκριτική αξιολόγηση και όχι απλώς παραλλαγή της ίδιας ιδέας.Δεδομένης της ανισορροπίας, εφαρμόστηκαν τεχνικές στάθμισης κλάσεων. Στα περισσότερα μοντέλα χρησιμοποιήθηκε class weighting, ώστε τα σφάλματα στη μειοψηφική κλάση να έχουν αυξημένη βαρύτητα. .Στο XGBoost χρησιμοποιήθηκε παράμετρος που σταθμίζει τη θετική κλάση ανάλογα με τη συχνότητά της.
Η λογική πίσω από αυτή την επιλογή είναι πρακτική σε ένα τραπεζικό σενάριο , όπου η απώλεια ενός πιθανού πελάτη το false negative, δηλαδή, μπορεί να έχει μεγαλύτερο κόστος από μία επιπλέον κλήση σε πελάτη που τελικά θα αρνηθεί.

Logistic Regression

Accuracy : 0.75047 | F1- Score : 0.3727 | ROC-AUC : 0.7636

Η Λογιστική Παλινδρόμηση (Logistic Regression) αποτελεί έναν από τους πιο κλασικούς αλγόριθμους δυαδικής ταξινόμησης. Πρόκειται για ένα γραμμικό μοντέλο που εκτιμά την πιθανότητα ένταξης ενός δείγματος στη θετική κλάση μέσω λογιστικής συνάρτησης.
Χρησιμοποιείται συχνά ως μοντέλο αναφοράς καθώς

- είναι ερμηνεύσιμο,
- έχει χαμηλή πολυπλοκότητα,
- παρέχει καλή βασική γραμμή σύγκρισης

Η Logistic Regression παρουσιάζει μέτρια συνολική απόδοση αλλά σχετικά σταθερή συμπεριφορά, όπως φαίνεται από τη μικρή διακύμανση των αποτελεσμάτων μεταξύ των folds. Το F1-score δείχνει ότι το μοντέλο μπορεί να εντοπίζει ένα ικανοποιητικό ποσοστό θετικών περιπτώσεων, χωρίς όμως να επιτυγχάνει άριστη ισορροπία μεταξύ precision και recall. Η επίδοση αυτή είναι αναμενόμενη, καθώς πρόκειται για γραμμικό μοντέλο που βασίζεται σε γραμμικό διαχωρισμό των κλάσεων. Σε δεδομένα, όπου οι σχέσεις μεταξύ μεταβλητών είναι πιο σύνθετες ή μη γραμμικές , η εκφραστική του ικανότητα είναι περιορισμένη. Παρόλα αυτά, η τιμή υποδηλώνει ικανοποιητική διαχωριστική ικανότητα μεταξύ των δύο κλάσεων. Η απλότητα και η ερμηνευσιμότητα του το καθιστούν χρήσιμο για την κατανόηση του προβλήματος. Για τον λόγο αυτό χρησιμοποιείται συχνά ως μοντέλο αναφοράς για σύγκριση με πιο σύνθετους αλγορίθμους.

Ο K-Nearest Neighbors είναι αλγόριθμος βασισμένος σε παραδείγματα. Δεν εκπαιδεύει ρητό μοντέλο, αλλά αποθηκεύει τα δεδομένα εκπαίδευσης και ταξινομεί νέα δείγματα με βάση τους k πιο κοντινούς γείτονες. Η απόδοση του εξαρτάται έντονα από :

- την κλίμακα των χαρακτηριστικών
- την επιλογή k
- τη μετρική απόστασης

K-Nearest Neighbors (KNN)

Accuracy : 0.8845 | F1- Score : 0.2827 | ROC-AUC : 0.6952

Ο αλγόριθμός K-Nearest Neighbors παρουσιάζει υψηλή ακρίβεια, όμως η μετρική αυτή δεν αποτυπώνει πλήρως την πραγματική του απόδοση. Το χαμηλό F1-Score δείχνει ότι το μοντέλο δυσκολεύεται να αναγνωρίσει αποτελεσματικά τη μειοψηφική κλάση. Αυτό υποδηλώνει ότι τείνει να προβλέπει συχνότερα την πλειοψηφική κατηγορία “no”, αυξάνοντας τεχνητά το accuracy. Σε ανισόρροπα σύνολα δεδομένων, μία τέτοια συμπεριφορά μπορεί να οδηγήσει σε παραπλανητικά συμπεράσματα. Η σχετικά χαμηλή τιμή ROC-AUC επιβεβαιώνει τη μέτρια διαχωριστική του ικανότητα. Συνεπώς, παρά την απλότητα του, δεν φαίνεται να αποτελεί την καταλληλότερη επιλογή για το συγκεκριμένο πρόβλημα.

Support Vector Machine Linear (SVM)

Accuracy : 0.8902 | F1- Score : 0.2549 | ROC-AUC : 0.7632

Ο SVM επιδιώκει να βρει το υπερεπίπεδο που διαχωρίζει τις κλάσεις μεγιστοποιώντας το περιθώριο μεταξύ τους. Είναι ιδιαίτερα αποτελεσματικό σε δεδομένα υψηλής διάστασης και συχνά παρουσιάζει καλή γενίκευση. Η γραμμική εκδοχή του είναι υπολογιστικά αποδοτική για μεγάλα σύνολα δεδομένων.

Ο Linear SVM παρουσιάζει υψηλή ακρίβεια , ωστόσο το χαμηλό F1- Score υποδηλώνει περιορισμένη απόδοση στην μειοψηφική κλάση. Η συμπεριφορά αυτή δείχνει ότι το μοντέλο είναι συντηρητικό και αποφεύγει να προβλέψει τη θετική κλάση οδηγώντας σε αυξημένα ψευδώς αρνητικά. Σε εφαρμογές marketing, όπου εντοπισμός πιθανών πελατών είναι κρίσιμος, αυτό αποτελεί σημαντικό μειονέκτημα παρότι η τιμή ROC-AUC είναι ικανοποιητική. Δεν συνοδεύεται από υψηλή ικανότητα ανίχνευσης θετικών περιπτώσεων . Συνεπώς η πρακτική αυτή του χρησιμότητα ,στο συγκεκριμένο πρόβλημα εμφανίζεται περιορισμένη σε σύγκριση με πιο ευέλικτα μοντέλα.

Random Forest

Accuracy : 0.8935 | F1- Score : 0.3062 | ROC-AUC : 0.7792

Ο Random Forest είναι μέθοδος συνόλων (ensemble method) που βασίζεται σε πολλά δέντρα απόφασης. Κάθε δέντρο εκπαιδεύεται σε διαφορετικό υποσύνολο δεδομένων και χαρακτηριστικών, ενώ η τελική πρόβλεψη προκύπτει μέσω πλειοψηφικής ψηφοφορίας μεταξύ των επιμέρους δέντρων. [3]

Πλεονεκτήματα:

- ανθεκτικότητα στον θόρυβο
- ικανότητα μοντελοποίησης μη γραμμικών σχέσεων
- καλή απόδοση σε ετερογενή δεδομένα

Ο Random Forest εμφανίζει βελτιωμένη ισορροπία απόδοσης σε σχέση με αλγορίθμους όπως ο KNN και ο SVM, γεγονός που αντανακλά τα πλεονεκτήματα των μεθόδων συνόλων. Η υψηλή τιμή ROC-AUC υποδηλώνει καλή διαχωριστική ικανότητα μεταξύ των δύο κλάσεων και δείχνει ότι το μοντέλο αναγνωρίζει ουσιαστικά μοτίβα στα δεδομένα. Παράλληλα, το σχετικά υψηλό accuracy δείχνει σταθερή συνολική απόδοση. Ωστόσο, το F1-score παραμένει μέτριο, κάτι που σημαίνει ότι η ισορροπία μεταξύ precision και recall στη μειοψηφική κλάση δεν είναι βέλτιστη. Παρόλα αυτά, η ανθεκτικότητά του στον θόρυβο και ικανότητά του να μοντελοποιεί μη γραμμικές σχέσεις το καθιστούν αξιόπιστη επιλογή. Συνολικά, μπορεί να θεωρηθεί ισχυρό μοντέλο, αν και όχι το κορυφαίο για το συγκεκριμένο στόχο.

XGBoost

Accuracy : 0.8374 | F1- Score : 0.4167 | ROC-AUC : 0.7543

Ο XGBoost αποτελεί υλοποίηση τεχνικών ενίσχυσης (boosting), όπου τα δέντρα εκπαιδεύονται διαδοχικά με κάθε νέο δέντρο να διορθώνει τα σφάλματα των προηγούμενων. Η προσέγγιση αυτή συχνά οδηγεί σε πολύ υψηλή προβλεπτική ικανότητα σε δομημένα δεδομένα. [2]

Ο XGBoost παρουσιάζει το υψηλότερο F1- Score μεταξύ όλων των μοντέλων , γεγονός που υποδηλώνει την καλύτερη ισορροπία μεταξύ precision και recall. Παρότι ,η ακρίβεια του είναι χαμηλότερη από άλλα μοντέλα, η μετρική αυτή είναι λιγότερο αξιόπιστη σε ανισόρροπα σύνολα δεδομένων. Η αυξημένη τιμή F1- Score δείχνει ότι το μοντέλο εντοπίζει αποτελεσματικότερα τις πραγματικές θετικές περιπτώσεις. Η επίδοση αυτή συνδέεται με τη λογική των τεχνικών boosting , όπου τα διαδοχικά μοντέλα διορθώνουν τα σφάλματα των προηγούμενων.Σε εφαρμογές marketing προτεραιότητα έχει ο εντοπισμός πιθανών πελατών. Η ιδιότητα αυτή είναι ιδιαίτερα σημαντική και για το λόγο αυτό ο XGBoost μπορεί να θεωρηθεί καταλληλότερη επιλογή για το συγκεκριμένο πρόβλημα .

	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.7547	0.266	0.6228	0.3727	0.7636
KNN	0.8845	0.5171	0.1948	0.2827	0.6952
SVM (Linear)	0.8902	0.6177	0.1607	0.2549	0.7632
Random Forest	0.8935	0.6423	0.2011	0.3062	0.7792
XGBoost	0.8374	0.3591	0.4966	0.4167	0.7543

ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ΥΠΕΡΠΑΡΑΜΕΤΡΩΝ

- Logistic Regression

Για τη Logistic Regression , η βελτιστοποίηση επικεντρώθηκε κυρίως στην παράμετρο κανονικοποίησης C . Η διαδικασία GridSearchCV έδειξε ότι η τιμή C =1 προσφέρει την καλύτερη ισορροπία μεταξύ underfitting και overfitting. Το μέγιστο F1-Score που επιτεύχθηκε ήταν 0.3727. Η σχετικά περιορισμένη βελτίωση υποδηλώνει ότι η απόδοση του μοντέλου επηρεάζεται περισσότερο από τη γραμμική του φύση παρά από τις υπέρ παραμέτρους.

- K-Nearest Neighbors (KNN)

Για τον K-Nearest Neighbors (KNN), εξετάστηκαν διαφορετικές τιμές γειτόνων , μετρικές αποστάσεις και σχήματα στάθμισης. Ο βέλτιστος συνδυασμός προέκυψε με τρεις γείτονες μετρική Manhattan και ομοιόμορφη στάθμιση. Το καλύτερο F1- Score σε Cross Validation ήταν 0.3112. Η ευαισθησία του K-Nearest Neighbors (KNN) στις υπερ-παραμέτρους είναι αναμενόμενη, καθώς η απόδοση του εξαρτάται άμεσα από τη γεωμετρία του χώρου χαρακτηριστικών.

- Linear SVM

Στην περίπτωση του Linear SVM, η βασική υπερ-παράμετρος που ρυθμίστηκε ήταν το C, το οποίο ελέγχει τον συμβιβασμό μεταξύ περιθωρίου και σφαλμάτων ταξινόμησης. Η βέλτιστη τιμή εντοπίστηκε στο C=10. Το αντίστοιχο F1-score ανήλθε σε 0.2553. Η σχετικά χαμηλή τιμή δείχνει ότι, παρά τη βελτιστοποίηση, το μοντέλο δυσκολεύεται να αποδώσει καλά στη μειοψηφική κλάση.

- Random Forest

Για το Random Forest, πραγματοποιήθηκε αναζήτηση υπερ-παραμέτρων με GridSearchCV και 5-fold Cross Validation. Η διαδικασία εξέτασε συνδυασμούς παραμέτρων που σχετίζονται με το βάθος των δέντρων , τον αριθμό των δέντρων και τα κριτήρια διαχωρισμού. Ο βέλτιστος συνδυασμός προέκυψε με μέγιστο βάθος 10, ελάχιστο αριθμό δειγμάτων διαχωρισμού 5 και 100 δέντρα. Το καλύτερο F1-score σε διασταυρωμένη επικύρωση ήταν 0.4395. Το αποτέλεσμα αυτό δείχνει ότι ο έλεγχος της πολυπλοκότητας των δέντρων συμβάλει σε καλύτερη γενίκευση.

- XGBoost

Στο XGBoost εφαρμόστηκε GridSearchCV με στόχο τη βελτιστοποίηση του F1-score. Δοκιμάστηκαν διαφορετικοί ρυθμοί μάθησης, βάθη δέντρων και αριθμοί εκτιμητών. Ο βέλτιστος συνδυασμός περιλάμβανε learning rate 0.05, μέγιστο βάθος 7 και 200 δέντρα. Το μοντέλο πέτυχε F1-score 0.4468 σε cross-validation, το υψηλότερο μεταξύ των εξεταζόμενων αλγορίθμων. Το αποτέλεσμα επιβεβαιώνει την ικανότητα των boosting τεχνικών να προσαρμόζονται αποτελεσματικά σε ανισόρροπα δεδομένα.

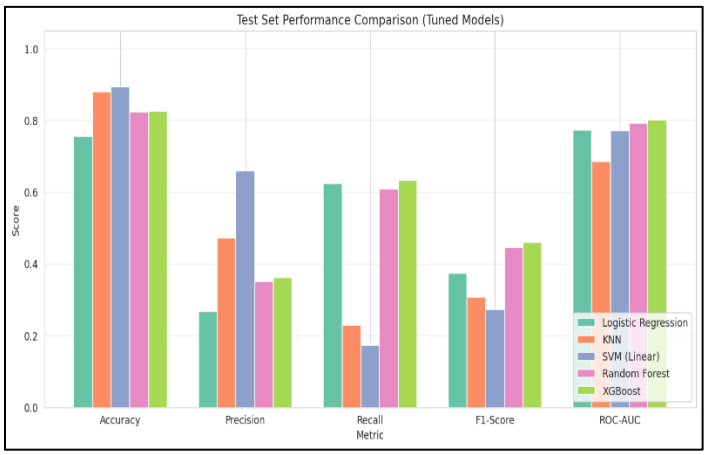

ΑΠΟΤΕΛΕΣΜΑΤΑ

- Logistic Regression

Σε σύγκριση με τα αρχικά αποτελέσματα Cross-Validation, η Logistic Regression διατηρεί σχεδόν ίδια απόδοση στο test set. Ιδιαίτερα ως προς το F1-score της θετικής κλάσης. Αυτό δείχνει ότι το μοντέλο παρουσιάζει σταθερότητα και καλή ικανότητα γενίκευσης. Η υψηλή τιμή recall για την κλάση “yes” επιβεβαιώνει ότι εντοπίζει αρκετούς πιθανούς θετικούς πελάτες αν και με χαμηλή τιμή precision. Συνολικά, δεν παρατηρείται ουσιαστική βελτίωση αλλά ούτε και υποβάθμιση της απόδοσης.

- K-Nearest Neighbors (KNN) [5]

Ο KNN παρουσιάζει παρόμοια εικόνα με τα αρχικά αποτελέσματα, διατηρώντας υψηλή ακρίβεια αλλά χαμηλή τιμή recall στη θετική κλάση. Το F1-score της κλάσης “yes” παραμένει σχετικά χαμηλό, γεγονός που δείχνει ότι το μοντέλο εξακολουθεί να δυσκολεύεται να εντοπίσει τους θετικούς πελάτες. Δεν παρατηρείται ουσιαστική βελτίωση μετά το tuning. Αυτό επιβεβαιώνει ότι ο KNN δεν είναι ιδανικός για το συγκεκριμένο ανισόρροπο πρόβλημα.

- Support Vector Machine Linear (SVM) [6] [7]

Ο Support Vector Machine Linear (SVM) εμφανίζει επίσης παρόμοια συμπεριφορά με πριν με πολύ υψηλή απόδοση στην κλάση “no” αλλά χαμηλή τιμή recall στην κλάση “yes”. Το μοντέλο παραμένει συντηρητικό στις θετικές προβλέψεις. Το F1-Score της θετικής κλάσης δεν παρουσιάζει βελτίωση σε σχέση με τα αρχικά αποτελέσματα, συνεπώς η συνολική του χρησιμότητα στο συγκεκριμένο πρόβλημα παραμένει περιορισμένη.

- Random Forest

Ο Random Forest παρουσιάζει εμφανή βελτίωση σε σχέση με τα αρχικά cross-validation αποτελέσματα. Το F1-score της κλάσης “yes” αυξάνεται σημαντικά, ενώ η τιμή recall παραμένει υψηλή. Αυτό δείχνει ότι η ρύθμιση υπερπαραμέτρων βοήθησε το μοντέλο να αναγνωρίζει καλύτερα τη μειοψηφική κλάση. Το μοντέλο επιτυγχάνει πλέον πιο ισορροπημένη απόδοση μεταξύ των δύο κλάσεων.

- XGBoost

Ο XGBoost επιβεβαιώνει και στο test set την καλή εικόνα που είχε δείξει στο Cross Validation. Το F1-score και το recall της κλάσης “yes” είναι τα υψηλότερα μεταξύ όλων των μοντέλων. Η απόδοση του εμφανίζεται ελαφρώς βελτιωμένη και ιδιαίτερα σταθερή. Αυτό δείχνει ότι το μοντέλο γενικεύει καλά και δεν υπερ προσαρμόστηκε στα δεδομένα εκπαίδευσης.

ΣΥΜΠΕΡΑΣΜΑΤΑ

Με βάση το τελικά αποτελέσματα, ο XGBoost αναδεικνύεται ως το καταλληλότερο μοντέλο για το συγκεκριμένο πρόβλημα πρόβλεψης ανταπόκρισης πελατών. Παρουσιάζει τον καλύτερο συνδυασμό τιμής recall και F1-score στη θετική κλάση, η οποία είναι και η πιο κρίσιμη σε εφαρμογές τραπεζικού μάρκετινγκ. Η υψηλή τιμή recall σημαίνει ότι το μοντέλο καταφέρνει να εντοπίζει μεγαλύτερο ποσοστό πελατών που έχουν πραγματική πιθανότητα να αποδεχτούν την προσφορά, μειώνοντας έτσι τον αριθμό χαμένων ευκαιριών. Παράλληλα, το F1-score δείχνει ότι αυτή η βελτίωση δεν επιτυγχάνεται εις βάρος υπερβολικού αριθμού ψευδώς θετικών προβλέψεων. Με τον τρόπο αυτό επιτυγχάνεται μια ισορροπία μεταξύ αποτελεσματικής στόχευσης πελατών και ελέγχου του

κόστους επικοινωνίας.

Επιπλέον, η σταθερή απόδοση του XGBoost τόσο στο Cross Validation όσο και στο τελικό test set υποδηλώνει καλή ικανότητα γενίκευσης, κάτι ιδιαίτερα σημαντικό για πραγματικές επιχειρησιακές εφαρμογές. Συνεπώς, το μοντέλο μπορεί να αποτελέσει αξιόπιστη βάση για συστήματα υποστήριξης αποφάσεων σε καμπάνιες μάρκετινγκ.

Ωστόσο, υπάρχουν περιθώρια περαιτέρω μελλοντικής βελτίωσης. Μια πιθανή κατεύθυνση είναι η χρήση τεχνικών επαναδειγματοληψίας όπως over-sampling της μειοψηφικής κλάσης ή SMOTE, ώστε να αντιμετωπιστεί πιο αποτελεσματικά η ανισορροπία κλάσεων. Επιπλέον, θα μπορούσε να εξεταστεί η ρύθμιση του κατωφλιού απόφασης ώστε αντί της προεπιλεγμένης τιμής 0,5 να επιλεχθεί άλλο κατώφλι, προκειμένου να επιτευχθεί διαφορετική ισορροπία μεταξύ precision και recall ανάλογα με τις επιχειρησιακές ανάγκες. Τέλος, η ενσωμάτωση περισσότερων ή πιο πρόσφατων δεδομένων πελατών, καθώς και η δοκιμή πιο εκτεταμένου hyperparameter tuning, θα μπορούσαν να ενισχύσουν περαιτέρω την απόδοση του μοντέλου.

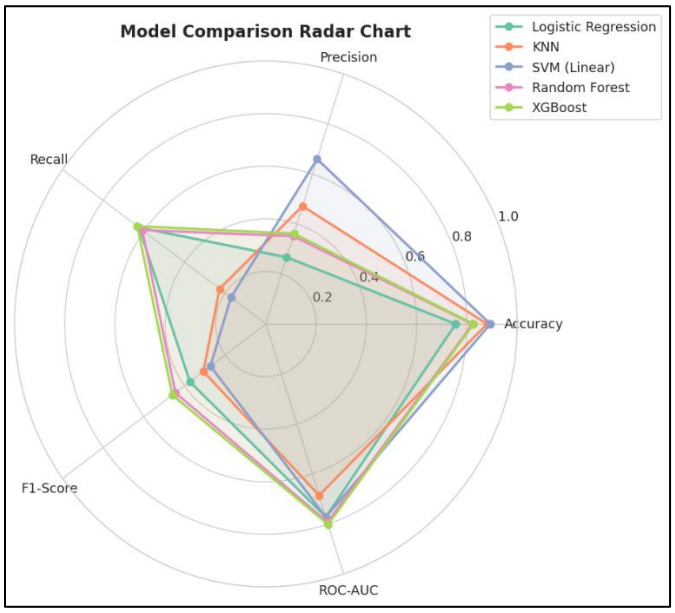

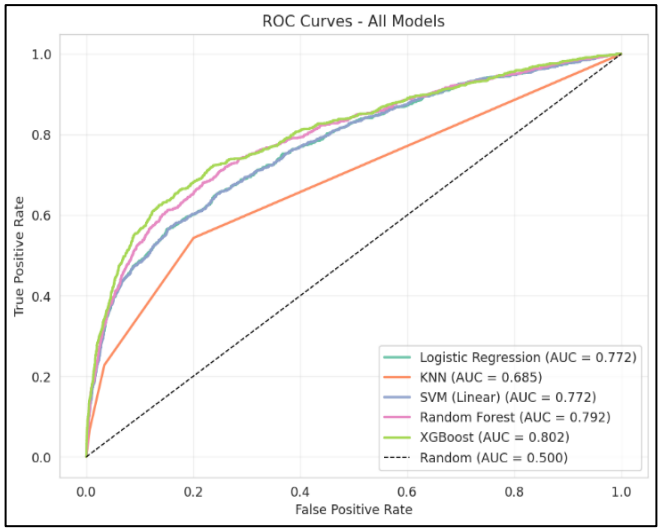

ΒΙΒΛΙΟΓΡΑΦΙΑ

[1] chromeextension://efaidnbmnnnibpcajpcglclefindmkaj/https://arxiv.org/pdf/2211.05456.

[2] https://medium.com/%40brandon93.w/decision-tree-random-forest-and-xgboost-an-exploration-into-the-heart-of-machine-learning-90dc212f4948

[3] https://scikit-learn.org/stable/